



COMILLAS

UNIVERSIDAD PONTIFICIA

ICAI

ICADE

CIHS

Aprendizaje por Refuerzo

Tema 1: Introducción

comillas.edu



Contenidos

- Intuición y evolución histórica del aprendizaje por refuerzo
- Conceptos clave:
 - Recompensa
 - Valores de acción
 - Dilema exploración - explotación





COMILLAS
UNIVERSIDAD PONTIFICIA

ICAI

ICADE

CIHS

Hace 250.000 años



comillas.edu



COMILLAS
UNIVERSIDAD PONTIFICIA

ICAI

ICADE

CIHS


Hace 250.000 años



comillas.edu

Dopamina

- Neurotrasmisor
- Sistema de recompensa
- Se generó en la imagen anterior. ¿Por qué?
- Neuronas dopaminérgicas en ATV






COMILLAS
UNIVERSIDAD PONTIFICIA

ICAI

ICADE

CIHS

Dopamina



RL en el mapa de la IA

	Supervised learning	Unsupervised learning	Reinforcement learning
Training data needed	Labeled data	Unlabeled data	EXPERIENCIA Synthetic data created as an agent interacts with the environment and receives feedback
Purpose	Predict the target variable for unlabeled observations, based on having learned from the labeled data	Identify groups of data that exhibit similar behavior	Identify an optimal sequence of actions to achieve an optimal outcome
Adaptability	Retraining of model required if underlying conditions change and cause accuracy to drift	Retraining of model required when changes occur in underlying data	System can adapt to changes (within a certain range) on its own

cor

Breve revisión histórica

- Tres **líneas de investigación** independientes **convergieron** (finales de los 80):
 - *Control óptimo* (programación dinámica)
 - Aprendizaje por *ensayo y error* (psicología del aprendizaje animal)
 - *Diferencia temporal* (interrelación de los anteriores).
- Pero... **capacidad limitada para escalar** a problemas grandes.
- En 2015, **Mnih et al.** publicaron “*Human-level control through deep reinforcement learning*”, donde **presentaron el modelo DQN**, que superó algunos de los problemas que impedían que el RL escalara...

Breve revisión histórica

- Podemos considerar esto como el primero de una larga lista de contribuciones de investigadores de **Deep Mind** al campo del Aprendizaje por Refuerzo (Profundo)
 - Doble y otras variantes del modelo DQN.
 - Alpha Go, Alpha Zero, Alpha Fold.
- Open AI impulsa *gym* y *baselines* → **aceleración** proyectos RL
 - Aplican RL a mejora de GPT-3 → boom de la IA generativa




Breve revision histórica


Step 1

Collect demonstration data, and train a supervised policy.


A prompt is sampled from our prompt dataset.



A labeler demonstrates the desired output behavior.




This data is used to fine-tune GPT-3 with supervised learning.



Step 2

Collect comparison data, and train a reward model.

A prompt and several model outputs are sampled.



A labeler ranks the outputs from best to worst.



This data is used to train our reward model.




Step 3

Optimize a policy against the reward model using reinforcement learning.

A new prompt is sampled from the dataset.



The policy generates an output.



The reward model calculates a reward for the output.



The reward is used to update the policy using PPO.




Figure 2: A diagram illustrating the three steps of our method: (1) supervised fine-tuning (SFT), (2) reward model (RM) training, and (3) reinforcement learning via proximal policy optimization (PPO) on this reward model. Blue arrows indicate that this data is used to train one of our models. In Step 2, boxes A-D are samples from our models that get ranked by labelers. See Section 3 for more details on our method.




Otras aplicaciones (negocio)

- Actualmente el **RL** se está adentrando en varios campos, incluso en la industria, donde la **fiabilidad** es fundamental → **madurez**.
- Echa un vistazo a este informe de McKinsey para ver cómo el RL está impactando en varios sectores industriales diferentes:

<https://www.mckinsey.com/business-functions/mckinsey-analytics/our-insights/its-time-for-businesses-to-chart-a-course-for-reinforcement-learning>

El esquema general de RL




En este primer tema

- Vamos a empezar de forma sencilla, con una configuración limitada del problema general de toma de decisiones secuenciales con realimentación evaluativa: *bandits* de k brazos (k-armed bandits).
- En este contexto, introduciremos conceptos importantes de RL:
 - Recompensa.
 - Valores.
 - Métodos de evaluación.
 - Exploración y explotación.




Simplificando el entorno de RL: *Bandits* de k brazos

- Antes de explorar el entorno general de RL, una simplificación:
bandit multibrazo



Ejemplos de problemas para un algoritmo de *bandit*

- Optimización de la publicidad en tiempo real
 - Graepel, T., Candela, J. Q., Borchert, T., & Herbrich, R. (2010). Web-Scale Bayesian Click-Through rate prediction for Sponsored Search Advertising in Microsoft's Bing Search Engine. Proceedings of the 27th International Conference on Machine Learning.
 - Li, L., Chu, W., Langford, J., & Schapire, R. E. (2010). A contextual-bandit approach to personalized news article recommendation. Proceedings of the 19th International Conference on World Wide Web.
- Medicina Personalizada y Pruebas Clínicas
 - Bastani, H., & Bayati, M. (2020). Online Decision-Making with High-Dimensional Covariates: An Application to Personalized Healthcare. Operations Research, 68(2), 533-556.
- Decisiones de Portafolio en Finanzas
 - de Freitas Fonseca, G., Coelho e Silva, L. & Lima de Castro, P.A. Improving Portfolio Optimization Results with Bandit Networks. Comput Econ 68, 739–778 (2026)..



Bandits de k brazos.

Recompensa y valor de acción

- En cada paso de tiempo, obtenemos una **recompensa** asociada con la **acción anterior**.
- Es entonces natural **asignar un escalar a las acciones** para 'clasificarlas'...
- **Llamamos a esto el valor de la acción**, y se puede definir como:

$$q_*(a) \doteq \mathbb{E}[R_t \mid A_t = a]$$

NOTA: Esta es la primera vez que hablamos sobre una función llamada q . ¿Te suena?

Bandits de k brazos. Un ejemplo sencillo



	5 J	Joselito	Covap
Customer 1	?	?	?
Customer 2			
Customer 3			
Customer 4			
...			
Customer n			



Bandoleros de k brazos. Un ejemplo sencillo



	5 J	Joselito	Covap
Customer 1	9.7		
Customer 2		9.8	
Customer 3			9.1
Customer 4		...	
...			
Customer n			



Bandits de k brazos. Un ejemplo sencillo



	5 J	Joselito	Covap
Customer 1	?	?	?
Customer 2			
Customer 3			
Customer 4			
...			
Customer n			

Política greedy

$$a_t = \underset{a}{\operatorname{argmax}} q_*(a)$$

Bandoleros de k brazos

Métodos de evaluación

- Podemos calcular el **promedio de la muestra** obtenida
- Por supuesto, es **calculado incrementalmente** con esta fórmula:

$$Q_{n+1} = Q_n + \frac{1}{n} [R_n - Q_n]$$

- Estructura **muy trasversal** en RL:

$$NewEstimate \leftarrow OldEstimate + StepSize [Target - OldEstimate]$$

- ¿Problemas, limitaciones con el método del promedio de la muestra?

Bandoleros de k brazos

Métodos de evaluación


- Podemos usar un **paso constante**:

$$Q_{n+1} = Q_n + \alpha [R_n - Q_n]$$

- Si elaboras la fórmula, puedes descubrir que esto resulta ser un **promedio ponderado exponencialmente por recencia**.
- También podemos hacer α **variable**. En este caso, para **convergencia**:



$$\sum_{n=1}^{\infty} \alpha_n(a) = \infty \quad \text{and} \quad \sum_{n=1}^{\infty} \alpha_n^2(a) < \infty$$

Dilema exploración - explotación




Estrategias de exploración

- Políticas ϵ -greedy
- Valores iniciales optimistas
- Límites de confianza superiores





El banco de pruebas del *bandit* de 10 brazos



- 10 palancas
- Valores promedio ($q^*(a)$) aleatorios muestreados de $N(0,1)$
- Entonces, valores de $N(q^*(a),1)$


Exploración ϵ -greedy

Rendimiento promedio
(2000 ejecuciones, evaluación promedio de la muestra)



Valores iniciales optimistas


Rendimiento promedio
(2000 ejecuciones, $\alpha = 0.1$)



- Los valores iniciales optimistas son un enfoque de exploración muy bueno.
- Son insensibles a los cambios en el entorno que ocurren después de un tiempo.



Límites de confianza superiores

$$A_t \doteq \arg \max_a \left[Q_t(a) + c \sqrt{\frac{\ln t}{N_t(a)}} \right]$$




- UCB suele funcionar mejor que ϵ -greedy.
- Es insensible a los cambios en el entorno que ocurren después de un tiempo.
- Es difícil extender a configuraciones generales de RL, especialmente a espacios de acciones complejos y aproximación de funciones.

Bandits asociativos y el entorno general de RL



El entorno general de RL



- El entorno tiene varios estados.
- Transicionamos a diferentes estados como resultado de nuestras acciones.
- De hecho, podemos cambiar el entorno con nuestras acciones.

Bandidos de gradiente

- Vamos a enmarcar nuestras acciones con una función de preferencia (H), que transformamos en una distribución de probabilidad para tener una política de actuación.

$$\Pr\{A_t = a\} \doteq \frac{e^{H_t(a)}}{\sum_{b=1}^k e^{H_t(b)}} \doteq \pi_t(a),$$

- Podemos aprender políticas optimizadas siguiendo una regla de ascenso de gradiente:

$$\begin{aligned} H_{t+1}(A_t) &\doteq H_t(A_t) + \alpha(R_t - \bar{R}_t)(1 - \pi_t(A_t)), & \text{and} \\ H_{t+1}(a) &\doteq H_t(a) - \alpha(R_t - \bar{R}_t)\pi_t(a), & \text{for all } a \neq A_t, \end{aligned}$$

