



COMILLAS

UNIVERSIDAD PONTIFICIA

ICAI


ICADE

CIHS

Procesos de Decisión de Markov (MDP)

comillas.edu

Tomemos algunas decisiones




Tomemos algunas decisiones

- A veces, las acciones dedicadas a obtener altas recompensas a corto plazo pueden hacernos **perder recompensas más altas a largo plazo**.
- Es entonces importante encontrar la **secuencias de acciones que maximizan** nuestro **retorno** absoluto
- Una forma conveniente de enmarcar este problema de decisión óptima bajo incertidumbre es formularlo como un **Proceso de Decisión de Markov (MDP)**.

Agente y entorno

- Estados (S_k)
- Recompensas (R_k)
- Acciones (A_k)



Secuencia: $S_0, A_0, R_1, S_1, A_1, \dots$



El modelo MDP

- Estudiamos **MDP finitos**
- Conjuntos importantes (estados, acciones y recompensas):

$$S_t \in \mathcal{S} \qquad A_t \in \mathcal{A}(s) \qquad R_{t+1} \in \mathcal{R} \subset \mathbb{R}$$

- Modelo para determinar las transiciones en el entorno → **dinámica del MDP:**

$$p(s', r | s, a) \doteq \Pr\{S_t = s', R_t = r \mid S_{t-1} = s, A_{t-1} = a\}$$

Un ejemplo

Estados

1	2	3
4	5	6
7	8	T


Acciones


Recompensas:

-1 para todas
las transiciones

$p(5, -1 | 2, \text{abajo}) = ?$ $p(5, -1 | 2, \text{izquierda}) = ?$ $p(5, 0 | 2, \text{abajo}) = ?$ $p(3, -1 | 3, \text{derecha}) = ?$



Estructura del modelo de transiciones (dinámica)





8 estados
4 acciones por estado



Estructura del modelo de transiciones (dinámica)

Como sólo hay un elemento en $R \rightarrow$
distribución discreta de 8 valores en
cada par (s,a)



De recompensa a retorno (y episodios)

- **La recompensa** está en el núcleo de los MDPs y del RL.
- Es la señal que **guía el aprendizaje**. Ojo con su diseño
- El **retorno** es la definición formal que permite a los agentes ser previsores:


$$G_t \doteq R_{t+1} + R_{t+2} + R_{t+3} + \cdots + R_T$$

- Si tenemos una secuencia de longitud infinita, puede diverger fácilmente → **retorno descontado**:

$$\begin{aligned} G_t &\doteq R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \cdots = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \\ &= R_{t+1} + \gamma G_{t+1} \end{aligned}$$

Política

- Una política es una función que **mapea estados a probabilidades** de tomar cada una de las posibles **acciones**.



$$\pi(a|3) = \begin{cases} 0,25 & \text{if } a = \text{top} \\ 0,25 & \text{if } a = \text{down} \\ 0,25 & \text{if } a = \text{left} \\ 0,25 & \text{if } a = \text{right} \end{cases}$$



Funciones de valor

- Las funciones de valor son elementos clave en RL. Muchos **algoritmos de RL usan funciones de valor**.
- Son una forma de **vincular estados y acciones al retorno**.
- Con ellas se pueden **inferir políticas**
- Dos funciones: **valor de estado y valor de acción**.

$$v_{\pi}(s) \doteq \mathbb{E}_{\pi}[G_t \mid S_t = s] = \mathbb{E}_{\pi}\left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \mid S_t = s\right], \text{ for all } s \in \mathcal{S}$$

$$q_{\pi}(s, a) \doteq \mathbb{E}_{\pi}[G_t \mid S_t = s, A_t = a] = \mathbb{E}_{\pi}\left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \mid S_t = s, A_t = a\right]$$

La función de valor de estado

- Se definen para una **política determinada**
- Se pueden formular de forma **recursiva**. Esto es muy importante.


$$\begin{aligned}\underline{v_\pi(s)} &\doteq \mathbb{E}_\pi[G_t \mid S_t = s] \\ &= \mathbb{E}_\pi[R_{t+1} + \gamma G_{t+1} \mid S_t = s] \\ &= \sum_a \pi(a|s) \sum_{s'} \sum_r p(s', r \mid s, a) \left[r + \gamma \mathbb{E}_\pi[G_{t+1} \mid S_{t+1} = s'] \right] \\ &= \sum_a \pi(a|s) \sum_{s', r} p(s', r \mid s, a) \left[r + \gamma v_\pi(s') \right], \quad \text{for all } s \in \mathcal{S},\end{aligned}$$

La ecuación de
Bellman para v_π

Navegación optimizada



- Cuadrícula (*gridworld*) de navegación muy simplificada.
- Podemos movernos hacia el norte, sur, este u oeste.
- Debemos llegar al estado terminal (un puerto marítimo) lo más rápido posible.
- En las transiciones generales, recibimos una recompensa de -1 por movernos. Rebotamos en celdas de contorno.
- Si entramos en el remolino → recompensa de -5.
- Zonas de viento siguen algunas reglas:
 - Si nos movemos en la dirección del viento → 0.25 probabilidad de movernos 2 celdas.
 - Si nos movemos en dirección opuesta al viento → 0.25 de probabilidad de no movernos

comillas.edu



Diagramas de *backup*

- Diagrama de *backup* para el estado 1



Ejercicio: Representa el diagrama de backup para el estado 3.

El SISTEMA de ecuaciones de Bellman

- Volvemos a la cuadrícula anterior
- ¿Cuántos valores de estado podemos definir? ¿Qué tipo de funciones manejamos?

- ¿Cómo podemos encontrar su solución?
- ¿Ventajas y desventajas de las alternativas?



1	2	3
4	5	6
7	8	T

Condiciones de optimalidad para las funciones de valor

- Las funciones de valor son óptimas si seguimos una política óptima.
- Los marcaremos con una estrella (*)
- La función de valor de estado óptima:

$$\begin{aligned} v_*(s) &= \max_{a \in \mathcal{A}(s)} q_{\pi_*}(s, a) \\ &= \max_a \mathbb{E}_{\pi_*}[G_t \mid S_t = s, A_t = a] \\ &= \max_a \mathbb{E}_{\pi_*}[R_{t+1} + \gamma G_{t+1} \mid S_t = s, A_t = a] \\ &= \max_a \mathbb{E}[R_{t+1} + \gamma v_*(S_{t+1}) \mid S_t = s, A_t = a] \\ &= \max_a \sum_{s', r} p(s', r \mid s, a) [r + \gamma v_*(s')]. \end{aligned}$$

¡Ojo!

Condiciones de optimalidad para las funciones de valor

- La función de valor de acción óptima:

$$q_*(s, a) = \mathbb{E}[R_{t+1} + \gamma v_*(S_{t+1}) \mid S_t = s, A_t = a]$$

- Diagramas de respaldo para $v_*(s)$ y $q_*(s, a)$

