



COMILLAS
UNIVERSIDAD PONTIFICIA

ICAI

ICADE

CIHS

Tema 3: Programación Dinámica

comillas.edu

Programación Dinámica

- Tres problemas: **predicción**, **control** y **planificación**.
- **Predicción** aquí: **encontrar los valores** de v y q bajo una cierta política.
- **Control**: **encontrar una política** que maximice la función de valor → **política óptima**
- **Planificación**: similar a **control**, pero haciendo uso de un **modelo del entorno**.

Predicción: Evaluación de una política

- Hay que **resolver** el sistema de ecuaciones de Bellman
- Nos enfocaremos en **métodos iterativos**, que son prevalentes en la práctica.

Iterative Policy Evaluation, for estimating $V \approx v_\pi$

Input π , the policy to be evaluated

Algorithm parameter: a small threshold $\theta > 0$ determining accuracy of estimation

Initialize $V(s)$, for all $s \in \mathcal{S}^+$, arbitrarily except that $V(\text{terminal}) = 0$

Loop:

$\Delta \leftarrow 0$

Loop for each $s \in \mathcal{S}$:


$v \leftarrow V(s)$

$V(s) \leftarrow \sum_a \pi(a|s) \sum_{s',r} p(s',r|s,a) [r + \gamma V(s')]$

$\Delta \leftarrow \max(\Delta, |v - V(s)|)$

until $\Delta < \theta$

¿Cómo encontrar una política óptima? (control)



(Teorema de) Mejora de la política

- Tenemos una función de valor de estado para una política dada (π), y una política alternativa (π') que es exactamente igual excepto en un estado, donde se cumple que:

$$q_{\pi}(s, \pi'(s)) \geq v_{\pi}(s)$$

- Es evidente que π **es igual o mejor que** π'
- Bueno, este es un caso particular de un teorema general llamado **teorema de mejora de la política**. Puedes encontrar la demostración en el libro.

Operadores de mejora de política

- Para explotar el teorema de mejora de política y obtener resultados prácticos, solo necesitamos un **operador de mejora** de política.
- El más común consiste en obtener la **política greedy** en todos los estados aplicando:

$$\pi'(s) \doteq \arg \max_a q_{\pi}(s, a)$$

- Es decir: Tomar cada estado, calcular la función de valor de acción para todas las acciones y asignar (de manera determinista) aquella que produzca el valor máximo a ese estado, rompiendo empates de forma arbitraria.

Control: Iteración de política

- En este punto, tenemos:
 - Un algoritmo para obtener (**predecir**) la **función de valor** para una política.
 - Un operador para **mejorar una política dada**.
- Podemos aplicar el **Algoritmo de ITERACIÓN DE POLÍTICA**:
 - **evaluación y mejora alternas** hasta que la política no cambie. ¡Si esto sucede, se garantiza que sea óptima!

$$\pi_0 \xrightarrow{E} v_{\pi_0} \xrightarrow{I} \pi_1 \xrightarrow{E} v_{\pi_1} \xrightarrow{I} \pi_2 \xrightarrow{E} \dots \xrightarrow{I} \pi_* \xrightarrow{E} v_*$$

Iteración de política: pseudocódigo

Policy Iteration (using iterative policy evaluation) for estimating $\pi \approx \pi_*$

1. Initialization
 $V(s) \in \mathbb{R}$ and $\pi(s) \in \mathcal{A}(s)$ arbitrarily for all $s \in \mathcal{S}$
2. Policy Evaluation
Loop:
 $\Delta \leftarrow 0$
 Loop for each $s \in \mathcal{S}$:
 $v \leftarrow V(s)$
 $V(s) \leftarrow \sum_{s',r} p(s', r | s, \pi(s)) [r + \gamma V(s')]$
 $\Delta \leftarrow \max(\Delta, |v - V(s)|)$
 until $\Delta < \theta$ (a small positive number determining the accuracy of estimation)
3. Policy Improvement
 policy-stable $\leftarrow$ true
 For each $s \in \mathcal{S}$:
 old-action $\leftarrow \pi(s)$
 $\pi(s) \leftarrow \arg\max_a \sum_{s',r} p(s', r | s, a) [r + \gamma V(s')]$
 If *old-action* $\neq \pi(s)$, then *policy-stable* $\leftarrow$ false
 If *policy-stable*, then stop and return $V \approx v_*$ and $\pi \approx \pi_*$; else go to 2

Iteración de política

Algunas consideraciones

Example 4.1 Consider the 4×4 gridworld shown below.




	1	2	3
4	5	6	7
8	9	10	11
12	13	14	

$R_t = -1$
on all transitions

Iteración de política

Algunas consideraciones



Control: Iteración de valor

- Este algoritmo responde a una pregunta muy específica:
 - ¿Necesitamos **esperar** hasta que el proceso de evaluación haya **convergado**?
 - ¿Qué pasa si aplicamos nuestro **operador de mejora antes**?
- Esta idea da lugar al **algoritmo de iteración de valor** que es la inspiración de muchos enfoques y modelos de RL.
- Importante: La iteración de valor tiene propiedades de convergencia hacia la función de valor óptima (y por lo tanto hacia una política óptima) con probabilidad 1 (en tiempo infinito). Sin embargo, **sus propiedades de convergencia pueden ser perfectamente peores que las de la iteración de políticas**

Control - planificación: Iteración de valor

Value Iteration, for estimating $\pi \approx \pi_*$

Algorithm parameter: a small threshold $\theta > 0$ determining accuracy of estimation
Initialize $V(s)$, for all $s \in \mathcal{S}^+$, arbitrarily except that $V(\text{terminal}) = 0$

Loop:

```
|  $\Delta \leftarrow 0$   
| Loop for each  $s \in \mathcal{S}$ :  
|    $v \leftarrow V(s)$   
|    $V(s) \leftarrow \max_a \sum_{s',r} p(s', r | s, a) [r + \gamma V(s')]$   
|    $\Delta \leftarrow \max(\Delta, |v - V(s)|)$   
until  $\Delta < \theta$ 
```

Output a deterministic policy, $\pi \approx \pi_*$, such that
$$\pi(s) = \operatorname{argmax}_a \sum_{s',r} p(s', r | s, a) [r + \gamma V(s')]$$

Iteración de Política Generalizada

- Cualquier enfoque basado en Iteración de Política siguiendo reglas heurísticas para mejorar propiedades de convergencia.
- **Iteración de Política Generalizada** está en el núcleo de muchos algoritmos de RL actuales.

