



COMILLAS

UNIVERSIDAD PONTIFICIA

ICAI

ICADE

CIHS

Tema 5.2: Métodos de gradiente de política

Métodos de gradiente de política: fundamentos

- Hasta este punto, hemos construido el comportamiento inteligente del agente a partir de los valores de acción. Las políticas ni siquiera existen sin q .
- Pero ahora estamos utilizando aproximaciones parametrizadas de q para resolver indirectamente la función real que realmente necesitamos, así que...

¿Qué tal si aprendemos directamente una política parametrizada?

Métodos de gradiente de política: fundamentos

- Para hacer esto, definimos nuestra política como una función de un conjunto de parámetros:

$$\pi(a|s, \theta) = \Pr\{A_t = a \mid S_t = s, \theta_t = \theta\}$$

- El problema consiste en maximizar una cierta medida de rendimiento escalar, que también es función de estos parámetros: $J(\theta)$
- Para hacerlo, podemos usar un enfoque de ascenso de gradiente, moviendo θ en la dirección que maximiza el aumento de J :

$$\theta_{t+1} = \theta_t + \alpha \widehat{\nabla J(\theta_t)}$$

Métodos de gradiente de política: fundamentos

- Todos los métodos que siguen este enfoque son conocidos como **métodos de gradiente de política**.
- A veces, se apoyan en una estimación de una función de valor. En este caso, se conocen como métodos actor-crítico.
- Algunos investigadores consideran los métodos actor-crítico como una tercera familia de métodos de RL, pero no hay consenso.

Ejemplo de política: preferencias + *softmax*

- Probablemente el enfoque más popular para espacios de acción finitos (discretos):

$$\pi(a|s, \theta) \doteq \frac{e^{h(s,a,\theta)}}{\sum_b e^{h(s,b,\theta)}}$$

- h es el vector de preferencias de acción, y es lo que aprendemos.
- La función *softmax* juega el papel de convertir h en una distribución de probabilidad.
- Como siempre, h puede variar desde una función lineal hasta una red neuronal profunda.

Métodos de gradiente de política: ventajas

- Flexibilidad. h , frente a ε -greedy, puede asignar masas de probabilidad arbitrarias a cada acción → política estocástica sin estructuras impuestas.
- La política varía suavemente con los cambios en h mientras que las políticas ε -greedy lo hacen a saltos → mejor convergencia con h .
- A menudo, la política es una función más simple de aproximar (depende del problema).
- Podemos inyectar fácilmente conocimiento previo en el problema en la política (recuerda: no en el diseño de la señal de recompensa).

El gradiente de la política

- Enfoquémonos en problemas episódicos, y definamos la medida de rendimiento como:

$$J(\theta) \doteq v_{\pi_{\theta}}(s_0)$$

- Recuerda: necesitamos el gradiente de J para mover θ en una buena dirección. A menudo, tendremos una estimación.
- Pues hay un problema: el rendimiento depende de la política (fácil de diferenciar) y la distribución de estados, que está fuertemente afectada por el entorno, y es función de θ .

El teorema del gradiente de la política

- Afortunadamente, contamos con el respaldo de un importante resultado teórico: el teorema del gradiente de la política:

$$\nabla J(\theta) \propto \sum_s \mu(s) \sum_a q_\pi(s, a) \nabla \pi(a|s, \theta)$$

- Ten en cuenta que solo menciona proporcionalidad, pero recuerda nuestra regla de actualización para θ :

$$\theta_{t+1} = \theta_t + \alpha \widehat{\nabla J(\theta_t)}$$

- Tenemos un parámetro arbitrario α que puede absorber efectivamente cualquier constante de proporcionalidad.

Estimando el gradiente de J: REINFORCE

- Nuestro objetivo es encontrar un método para obtener muestras cuya esperanza se aproxime al gradiente:

$$\begin{aligned}\nabla J(\theta) &\propto \sum_s \mu(s) \sum_a q_\pi(s, a) \nabla \pi(a|s, \theta) \\ &= \mathbb{E}_\pi \left[\sum_a q_\pi(S_t, a) \nabla \pi(a|S_t, \theta) \right].\end{aligned}$$

$$\begin{aligned}\nabla J(\theta) &= \mathbb{E}_\pi \left[\sum_a \pi(a|S_t, \theta) q_\pi(S_t, a) \frac{\nabla \pi(a|S_t, \theta)}{\pi(a|S_t, \theta)} \right] \\ &= \mathbb{E}_\pi \left[q_\pi(S_t, A_t) \frac{\nabla \pi(A_t|S_t, \theta)}{\pi(A_t|S_t, \theta)} \right] && \text{(replacing } a \text{ by the sample } A_t \sim \pi) \\ &= \mathbb{E}_\pi \left[G_t \frac{\nabla \pi(A_t|S_t, \theta)}{\pi(A_t|S_t, \theta)} \right], && \text{(because } \mathbb{E}_\pi[G_t|S_t, A_t] = q_\pi(S_t, A_t))\end{aligned}$$

Estimando el gradiente de J: REINFORCE


- Con el resultado anterior, tenemos la regla de actualización REINFORCE para aprender θ de la experiencia:

$$\theta_{t+1} \doteq \theta_t + \alpha \underbrace{G_t}_{\pi(A_t|S_t, \theta_t)} \frac{\nabla \pi(A_t|S_t, \theta_t)}{\pi(A_t|S_t, \theta_t)}.$$

- ¿on-policy u off-policy? ¿Online u offline?
- Con bastante frecuencia en la literatura, encontrarás la función *score* en lugar del gradiente de la política entre la política.

$$\nabla \ln \pi(A_t|S_t, \theta_t) \quad \longleftrightarrow \quad \frac{\nabla \pi(A_t|S_t, \theta_t)}{\pi(A_t|S_t, \theta_t)}$$

Estimando el gradiente de J: REINFORCE



Mejorando la rapidez: REINFORCE + baseline

- Podemos agregar una línea base arbitraria a la expresión del gradiente de J:

$$\nabla J(\theta) \propto \sum_s \mu(s) \sum_a \left(q_\pi(s, a) - b(s) \right) \nabla \pi(a|s, \theta)$$


- ¿Bajo qué condiciones? ¿Por qué?
- Es sencillo derivar la regla de actualización para REINFORCE con línea base:

$$\theta_{t+1} \doteq \theta_t + \alpha \left(G_t - b(S_t) \right) \frac{\nabla \pi(A_t|S_t, \theta_t)}{\pi(A_t|S_t, \theta_t)}$$

- ¿Cuál es el papel de la línea base? ¿Cómo lidiamos con ella?

Mejorando la convergencia: REINFORCE + línea base

- Mucho mejor rendimiento de convergencia.
- Dos hiperparámetros.



Métodos actor-crítico


- Recuerda: $\nabla J(\theta) = \mathbb{E}_{\pi} \left[q_{\pi}(S_t, A_t) \frac{\nabla \pi(A_t | S_t, \theta)}{\pi(A_t | S_t, \theta)} \right]$
- A-C utiliza un estimador sesgado (*bootstrap*) de $q(s,a)$ y el valor $v(s)$ como *baseline*
- Tienen una varianza definitivamente reducida que muestra un rendimiento claramente mejor que REINFORCE + baseline.

Métodos actor-crítico

- Sin embargo, la estructura de las actualizaciones de actor-critic es similar a las anteriores. Para el caso de un paso:

$$\begin{aligned}\theta_{t+1} &\doteq \theta_t + \alpha \left(G_{t:t+1} - \hat{v}(S_t, \mathbf{w}) \right) \frac{\nabla \pi(A_t | S_t, \theta_t)}{\pi(A_t | S_t, \theta_t)} \\ &= \theta_t + \alpha \left(R_{t+1} + \gamma \hat{v}(S_{t+1}, \mathbf{w}) - \hat{v}(S_t, \mathbf{w}) \right) \frac{\nabla \pi(A_t | S_t, \theta_t)}{\pi(A_t | S_t, \theta_t)} \\ &= \theta_t + \alpha \delta_t \frac{\nabla \pi(A_t | S_t, \theta_t)}{\pi(A_t | S_t, \theta_t)}.\end{aligned}$$

Métodos actor-crítico



$$\theta_{t+1} = \theta_t + c \delta_t \frac{\nabla \pi(A_t | S_t, \theta_t)}{\pi(A_t | S_t, \theta_t)}$$

Algoritmo actor-crítico de ventaja a un paso

function ONE-STEP ACTOR CRITIC

Initialise s, θ

for $t = 0, 1, 2, \dots$ **do**

Sample $A_t \sim \pi_{\theta}(S_t)$

Sample R_{t+1} and S_{t+1}

$\delta_t = R_{t+1} + \gamma v_{\mathbf{w}}(S_{t+1}) - v_{\mathbf{w}}(S_t)$

$\mathbf{w} \leftarrow \mathbf{w} + \beta \delta_t \nabla_{\mathbf{w}} v_{\mathbf{w}}(S_t)$

$\theta \leftarrow \theta + \alpha \delta_t \nabla_{\theta} \log \pi_{\theta}(A_t \mid S_t)$



Notas, consideraciones, precauciones...

- Por supuesto, se puede usar el retorno λ , e implementarlo con trazas de elegibilidad.
- Esta forma de buscar el gradiente es ya muy general. La mayor parte de los métodos que encontramos como estado del arte son extensiones o variaciones de esta idea.
- Cuando usamos un método de gradiente de política, es importante tener en cuenta que la política me va a condicionar fuertemente la experiencia con la que entreno al agente.
- Puedo estar progresando bien y un mal movimiento de la política hace que a partir de ahí solo obtenga experiencia irrelevante, que destruirá la aproximación de la política con el tiempo.

Mejoras

- Intuición: saltos bruscos en la política son los sospechosos habituales del colapso del entrenamiento.
- IDEA CLAVE: Añadir un término de regularización, al estilo de la L2 en SL.
- Ejemplo: Podemos usar la divergencia de Kullback-Leibler como la “medida” de la distancia entre la política actual y su actualización. Bastaría con calcularla y definir una función objetivo como $J - \eta * DKL$, con η como un hiperparámetro que modula la regularización.
- Éstas son las ideas detrás de algoritmos como TRPO o PPO.

Manejo de espacios de acción continuos

- Primero, hay que decir que la discretización (aunque sea gruesa) de acciones continuas, generalmente funciona bien.
- Sin embargo, los métodos de gradiente de política pueden tener espacios de acción continuos como salida.
- Esto se puede realizar simplemente aproximando los parámetros de una distribución continua. Si usamos una distribución normal, la política se vería así:

$$\pi(a|s, \theta) \doteq \frac{1}{\sigma(s, \theta)\sqrt{2\pi}} \exp\left(-\frac{(a - \mu(s, \theta))^2}{2\sigma(s, \theta)^2}\right)$$